

**UNIVERSIDAD NACIONAL JORGE BASADRE GROHMANN – TACNA – PERÚ**  
**FACULTAD DE INGENIERIA**  
**ESCUELA PROFESIONAL DE INGENIERÍA EN INFORMATICA Y SISTEMAS**

---

**SILABO DE INTELIGENCIA ARTIFICIAL**

**I. DATOS GENERALES**

1.1	Carrera de Estudio	:	Ingeniería en Informática y Sistemas
1.2	Área Curricular	:	Estudios Especialidad
1.3	Departamento Académico	:	Ingeniería en Informática y Sistemas
1.4	Código	:	19.09450
1.5	Currículo: Año/Código	:	2018/ESIS-F2
1.6	Año Académico	:	2022-I
1.7	Semestre de estudios	:	Noveno
1.8	Modalidad	:	Semipresencial
1.9	Duración del semestre	:	18 semanas (16/05/2022 – 16/09/2022)
1.10	Horas	:	06 horas (02 HT, 02 HP, 02 HL)
1.11	Créditos	:	04 créditos
1.12	Prerrequisitos	:	Ninguno
1.13	Docente	:	MSc.(c) Israel N. Chaparro Cruz
1.14	Correo electrónico institucional	:	<a href="mailto:ichaparroc@unibg.edu.pe">ichaparroc@unibg.edu.pe</a>

**II. SUMILLA**

**a) Naturaleza**

La asignatura corresponde al área de formación especializada.

**b) Propósito**

La asignatura es de carácter teórico-práctico.

**c) Contenidos centrales**

Fundamentos de la Inteligencia Artificial, conceptos, paradigmas y aplicaciones en la industria y servicios; Bases matemáticas: Representación de problemas de IA como búsqueda en el espacio de estado. Métodos de búsqueda ciegos e informados. Juegos inteligentes hombre-máquina. Redes Neuronales Artificiales (RNA) mediante agentes inteligentes.

La primera unidad está relacionada con Modelos matemáticos de la imagen y la segunda unidad algoritmos neuronales del reconocimiento de patrones binarizados.

**III. COMPETENCIAS**

**3.1. Competencia Genéricas Institucionales:**

Expresa ideas y conceptos mediante representaciones lingüísticas, matemáticas o gráficas, se comunica en español y en una lengua extranjera u originaria para ampliar sus redes académicas, sociales y profesionales a nivel nacional e internacional.

**3.2. Competencias del Perfil de Egreso:**

- Describe y formula las imágenes mediante modelos matemáticos casuísticos.
- Obtiene y procesa la imagen adecuadamente aplicando filtros discretos.

#### IV. ORGANIZACIÓN DE LOS CONTENIDOS Y ACTIVIDADES

UNIDAD I: FUNDAMENTOS DE REDES NEURONALES			
<b>Resultado de aprendizaje de la Competencia Genérica Institucional:</b> Expresa ideas y conceptos mediante representaciones matemáticas respecto a redes neuronales.			
<b>Resultado de aprendizaje de la Competencias del perfil de egreso:</b> Describe y formula modelos matemáticos de redes neuronales. Obtiene y procesa imágenes adecuadamente usando redes neuronales.			
<b>Evidencia:</b> Exámenes, Informe de Trabajo, Participación del Alumno. Prácticas de Laboratorio (LAB).			
Semana %	CONTENIDOS		ESTRATEGIAS DIDÁCTICAS
	Conceptuales (HT)	Procedimentales (HP, HL)	
1 (6 %)	<b>Introducción a la Inteligencia Artificial:</b> Conceptos, paradigmas y aplicaciones en la industria y servicios; Bases matemáticas: Representación de problemas de IA como búsqueda en el espacio de estado. Métodos de búsqueda ciegos e informados.	Presentación del Syllabus Entender como está construido un cerebro (o cómo creemos que lo está). Construir una neurona (simplificada). Entrenar y evaluar un modelo para el conjunto de datos Fashion-MNIST.	Clase magistral Clase de instrucción guiada Aprendizaje basado en problemas Aprendizaje basado en casos Aprendizaje basado en proyectos
2 (12 %)	<b>Entorno, tensores y CUDA:</b> Introducción a Google Colab, historia de las redes neuronales, conceptos básicos de redes neuronales e introducción a Pytorch.	Utilizar el entorno Google Colab. Aprender acerca de Pytorch y tensores. Manipular tensores. Cargar datos y visualizarlos. Diferenciar entre tensores en CUDA y CPU. Entrenar una red neuronal simple.	
3 (18%)	<b>Modelos lineales y autodiferenciación:</b> Gradientes, AutoGrad, regresión lineal, concepto de optimización, funciones de pérdida, diseño de sistemas lineales profundos y cómo entrenarlos.	Entender el descenso por gradiente. Utilizar el motor de autodiferenciación. Usar módulos nn de pytorch. Comprender el entrenamiento de redes neuronales. Experimentar el efecto de la profundidad en las redes neuronales. Elegir una ratio de aprendizaje. Comprender la importancia de la inicialización. Implementar redes neuronales lineales. Utilizar dinámicas de aprendizaje. Analizar la similitud representacional. Entender las correlaciones ilusorias y la ética.	
4 (24 %)	<b>Multi-layer Perceptrons (MLPs), redes profundas y anchas:</b> Inspiración en la neurociencia, resolución del problema XOR con MLP, la aproximación de funciones, la validación cruzada, el entrenamiento y las compensaciones.	Diferenciar las redes neuronales biológicas de las redes neuronales artificiales. Aproximar funciones con redes neuronales. Implementar una Multi-layer Perceptron (MLP). Entender la diferencia entre redes profundas y anchas. Comprender las funciones de transferencia. Inicializar parámetros de redes neuronales	
5 (30 %)	<b>Optimización:</b> Optimización convexa y no convexa, dificultades en la optimización, técnicas usuales de optimización.	Entender la necesidad e importancia de la optimización. Analizar las técnicas usuales de optimización. Optimizar en funciones no convexas. Ajustar hiperparámetros adaptativamente. Entender implicancias éticas.	
6 (36 %)	<b>Regularización:</b> El problema del sobreajuste, generalización y memorización, early stopping, normas vectoriales, aumento de datos.	Utilizar las redes neuronales artificiales como aproximadores universales. Entender la generalización y memorización en las redes neuronales artificiales. Regularizar utilizando early stopping (parada anticipada), norma L1 y L2, aumento de datos. Experimentar los peligros del ajuste de los hiperparámetros. Repensar la generalización.	

7 (42 %)	<b>Compartiendo de parámetros: Convnets y RNN:</b> Cantidad de parámetros y generalización, redes neuronales convolucionales (Convnets), redes neuronales recurrentes (RNN).	Definir qué es una convolución. Implementar una convolución como una operación. Entrenar una Convnet. Reconocer los síntomas de sobreajuste y como curarlos. Entender la estructura de una red neuronal recurrente (RNN). Implementar un modelo de RNN simple.	
8 (47 %)	Examen de <b>conocimiento (EC1)</b> , Examen de laboratorio/ <b>desempeño (EL1)</b> , Informe de trabajo 1/ <b>producto (IT1)</b>	Resolver el examen de conocimientos. Implementar el examen de laboratorio. Presentar el informe de trabajo 1.	

## UNIDAD II: FUNDAMENTOS DE APRENDIZAJE PROFUNDO (Deep Learning)

### Resultado de aprendizaje de la Competencia Genérica Institucional:

Expresa ideas y conceptos mediante representaciones matemáticas respecto a aprendizaje profundo.

### Resultado de aprendizaje de la Competencias del perfil de egreso:

Describe y formula modelos matemáticos de aprendizaje profundo.

Obtiene y procesa imágenes adecuadamente usando aprendizaje profundo.

**Evidencia:** Exámenes, Informe de Trabajo, Participación del Alumno. Prácticas de Laboratorio (**LAB**).

Semana %	CONTENIDOS		ESTRATEGIAS DIDÁCTICAS
	Conceptuales	Procedimentales	
9 (53 %)	<b>Convnets modernas:</b> Redes neuronales convolucionales modernas, transferencia de aprendizaje (transfer learning), reconocimiento facial, ética en reconocimiento facial.	Aprender acerca de las CNN y la transferencia de aprendizaje. Entender como las arquitecturas incorporan ideas de cómo entendemos el mundo. Comprender los principios operativos detrás de los bloques que componen los modelos modernos de CNN. Reconocer oportunidades para aplicar transfer learning. Entender el contrapeso entre velocidad y precisión. Aplicar un modelo de CNN moderno para el reconocimiento facial. Comprender los aspectos éticos del reconocimiento facial.	Clase magistral Clase de instrucción guiada Aprendizaje basado en problemas Aprendizaje basado en casos Aprendizaje basado en proyectos
10 (59 %)	<b>RNNs Modernas:</b> Memoria, series temporales, recurrencia, gradientes de desaparición e incrustaciones, LSTM, GRU, atención.	Describir las redes neuronales recurrentes modernas y su uso. Entender la memoria a corto plazo (LSTM), la unidad recurrente cerrada (GRU) y la célula de memoria. Utilizar redes de secuencia a secuencia y codificador-decodificador. Estudiar modelos de atención para la clasificación de textos.	
11 (65 %)	<b>Modelos de atención y Transformers:</b> Atención, autoatención, Transformers.	Explicar el mecanismo general de atención mediante claves, consultas y valores Mencionar tres aplicaciones en las que la atención es útil Explicar por qué Transformer es más eficiente que RNN Implementar la autoatención en Transformer Comprender el papel de la codificación de la posición en Transformer	
12 (71 %)	<b>Modelos generativos (VAEs y GAN):</b> Espacio latente, Codificadores automáticos variacionales (VAEs), redes adversarias generativas (GAN).	Reflexionar sobre el aprendizaje no supervisado/Modelos Generativos. Construir la intuición sobre las variables latentes. Ver la conexión entre los AutoEncodificadores y el PCA. Pensar en las redes neuronales como modelos generativos contrastando los AutoEncoders y los AutoEncoders Variacionales. Entender, cómo se implementan las GANs. Comprender la dinámica de entrenamiento de los GAN. Conocer algunos modos de fallo en el entrenamiento de GANs. Entender la estimación de la relación de densidad utilizando un clasificador binario. Entender la conexión entre los GANs y otros modelos generativos. Implementar un GAN. Entender las diferencias en los GANs condicionales. Generar imágenes naturales de alta dimensión a partir de un BigGAN. Entender la eficacia de los GANs en el modelado de la distribución de datos (por ejemplo, caras). Comprender la ineficiencia energética/el impacto medioambiental del	

		entrenamiento de grandes modelos generativos. Comprender las implicaciones de esta tecnología (ética, medio ambiente, etc.).	
13 (77 %)	<b>Aprendizaje supervisado no y autosupervisado:</b> Aprendizaje sin supervisión directa, aprendizaje autosupervisado.	Entrenar las regresiones logísticas directamente en los datos de entrada y en las representaciones aprendidas de los datos. Comparar los resultados de clasificación obtenidos por las distintas redes. Compare las representaciones aprendidas por las diferentes redes. Identifique las ventajas del aprendizaje autosupervisado sobre los métodos supervisados o no supervisados tradicionales.	
14 (83 %)	<b>Ideas básicas de aprendizaje por refuerzo (RL):</b> Reinforcement Learning, Q-learning, ecuación de Bellman.	Dentro del marco de la LR, ser capaz de identificar los diferentes componentes: Entorno, Agente, Estados y Acciones. Comprender la ecuación de Bellman y los componentes involucrados. Implementar el aprendizaje sin modelo basado en valores tabulares (Q-learning y SARSA). Discutir las aplicaciones del mundo real y las cuestiones éticas de la RL.	
15 (89 %)	<b>Aprendizaje por refuerzo para juegos:</b> Red de valor, política, juegos de dos jugadores, ejemplo práctico con RL aplicado a Go.	Comprender el formato de los juegos de dos jugadores Más información sobre la red de valor y la red de políticas	
16 (95 %)	<b>Aprendizaje continuo (CL) y causalidad:</b> Métricas de evaluación, Aprendizaje fuera de distribución, transferencia de aprendizaje, metalearning, aprendizaje multi-área.	Introducir los principales conceptos de CL Introducir las estrategias más comunes para ayudar a CL Utilizar puntos de referencia y métricas de evaluación Explore las aplicaciones actuales de CL Introducción al aprendizaje OOD Transferencia de aprendizaje Aprendizaje multitarea Meta-learning	
17 (100%)	Examen de <b>conocimiento (EC2)</b> , Examen de laboratorio/ <b>desempeño (EL2)</b> , Informe de trabajo 1/ <b>producto (IT2)</b>	Resolver el examen de conocimientos. Implementar el examen de laboratorio. Presentar el informe de trabajo 2.	
18 (100%)	<b>EXAMEN SUSTITUTORIO</b>		

## V. SISTEMA DE EVALUACIÓN

### 5.1. MATRIZ DE EVALUACIÓN

UNIDAD	PRODUCTO ACADÉMICO	TÉCNICA DE EVALUACIÓN	INSTRUMENTO DE EVALUACIÓN	PORCENTAJE	PROMEDIO
I	Evidencias de conocimiento	Examen escrito	Puntuaciones de examen	45%	9.00
	Evidencias de desempeño	Examen de laboratorio	Puntuaciones de examen	35%	7.00
	Evidencias de producto	Proyecto	Puntuaciones por objetivos	20%	4.00
<b>PROMEDIO PRIMER PARCIAL</b>					<b>20.00</b>
II	Evidencias de conocimiento	Exámenes escritos	Puntuaciones de examen	45%	9.00
	Evidencias de desempeños	Observación	Puntuaciones de examen	35%	7.00
	Evidencias de producto	Proyecto	Puntuaciones por objetivos	20%	4.00
<b>PROMEDIO SEGUNDO PARCIAL</b>					<b>20.00</b>

## 5.2. PROMEDIOS

PRIMER PARCIAL	SEGUNDO PARCIAL
$PP1 = 0.45*PEC + 0.35*PED + 0.20*PEP$	$PP2 = 0.45*PEC + 0.35*PED + 0.20*PEP$
Donde: PP1: Promedio Parcial 1 PEC: Promedio evidencia de conocimiento PED: Promedio evidencia de desempeño PEP: Promedio evidencia de producto	Donde: PP2: Promedio Parcial 2 PEC: Promedio evidencia de conocimiento PED: Promedio evidencia de desempeño PEP: Promedio evidencia de producto

PROMEDIO FINAL	CRITERIOS BÁSICOS
$PF = (PP1 + PP2)/2$ Dónde: PF: Promedio Final PP1: Promedio Parcial 1 PP2: Promedio Parcial 2	- El promedio final aprobatorio mínimo será de 10.5. - Antes de la finalización del semestre se dará al estudiante la oportunidad de un examen sustitutorio, que reemplazará a la nota menor de uno de los promedios (primer parcial o segundo parcial).

## VII. BIBLIOGRAFÍA

### a) Bibliografía básica

Nº	CÓDIGO UBICACIÓN	AUTOR	TÍTULO	AÑO
01	Aula Virtual	Ian Goodfellow et al.	Deep Learning	2016
02	Aula Virtual	Aurélien Géron	Aprende Machine Learning con Scikit-Learn, Keras y Tensorflow	2020
03	Aula Virtual	Aston Zhang et al.	Dive into Deep Learning	2022
04	Aula Virtual	Magnus Ekman	Learning Deep Learning	2021

Tacna, mayo de 2022